

O corpus do projeto: notícias e história da Baixada Santista

DataMortes

6 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.
João Paulo Ferreira de Mello

Enzo Shinji Sugano Ura – RA 0051352511025

Felipe Juca Gozza Borges – RA 0051352411031

Victor Ferreira Santos – RA 0051352511028

Repositório:

<https://github.com/felipejucaborges-oss/Projeto-integrador-III-Data-Mortes>

1 Introdução

O projeto tem como tema um motor de busca voltado para notícias e informações históricas da Baixada Santista. A proposta é organizar textos sobre municípios e locais de interesse da região para permitir que um usuário encontre documentos relacionados às suas necessidades de informação. Neste primeiro momento, foram definidas três perguntas de referência: “Quais são os marcos históricos da fundação de São Vicente e Santos?”, “Qual a importância militar e turística da Fortaleza de Itaipu em Praia Grande?” e “Como se desenvolveu o comércio do café no porto de Santos?”. Essas perguntas orientam a escolha das fontes e permitem verificar posteriormente se o corpus é adequado para a recuperação de informação.

A recuperação de informação trabalha com a representação e a organização de documentos para que consultas possam retornar resultados relevantes. Assim, esta entrega apresenta a fonte escolhida, explica como os documentos foram coletados e transformados em um corpus e registra um diagnóstico inicial de sua composição.

2 A fonte e o documento

A fonte utilizada no notebook foi a Wikipédia em português, consultada por meio de sua API. Foram selecionadas três páginas diretamente relacionadas ao tema regional: *Santos*, *Fortaleza de Itaipu* e *São Vicente (São Paulo)*. A escolha foi motivada pela disponibilidade de textos históricos e descritivos em uma mesma fonte e pela relação direta dessas páginas com as três perguntas definidas para o motor.

No procedimento de coleta, cada página foi solicitada à API com a opção de obter o texto sem a marcação da Wikipédia. O notebook registrou 54.140 caracteres para Santos, 3.456 para Fortaleza de Itaipu e 13.227 para São Vicente. A unidade utilizada no corpus não foi a página inteira: os textos foram separados em parágrafos, e cada parágrafo com mais de 200 caracteres foi tratado como um documento. Essa escolha produz unidades menores que um artigo completo, permitindo que o sistema retorne trechos mais específicos para uma consulta.

O corpus final obtido no notebook contém 55 documentos provenientes das três páginas. A fonte é adequada como primeira base porque contém informações sobre história, economia, turismo, infraestrutura e acontecimentos ligados à Baixada Santista. Ao mesmo tempo, a análise mostra que a fonte não é equilibrada entre as três páginas, o que precisa ser considerado nas etapas seguintes.

3 Como o corpus foi obtido

A coleta começou com uma função em R utilizando a biblioteca `httr2`. A função recebe o título de uma página, consulta a API da Wikipédia em português e recupera o texto puro do artigo. Depois da coleta, cada artigo foi separado em parágrafos. Foram removidos parágrafos vazios e aqueles com menos de 50 caracteres na etapa inicial. Em seguida, foi aplicado o critério principal da entrega: somente textos com mais de 200 caracteres entraram no corpus.

O resultado foi de 55 documentos, quantidade que está dentro do intervalo de 20 a 60 documentos estabelecido para a entrega. O código também continha uma rotina para dividir parágrafos muito grandes quando o corpus tivesse menos de 20 documentos; nesse caso, os segmentos seriam formados sem cortar palavras. Como o corpus alcançou 55 documentos diretamente após o filtro, essa expansão não foi necessária.


A inspeção revelou documentos com quantidade de tokens acima do limite adotado para suspeita. Foram encontrados 11 documentos com mais de 300 tokens. Eles foram inspecionados individualmente; exemplos incluem trechos sobre história, turismo, urbanização, mídia e cultura de Santos, além de trechos históricos sobre a Fortaleza de Itaipu e São Vicente. Não foram encontrados documentos com menos de 20 tokens. Também foram identificadas acentuação, pontuação e números no texto bruto. Esses elementos não foram

tratados como erro nesta etapa, pois a limpeza linguística foi realizada posteriormente no notebook.

4 Defesa do corpus

O diagnóstico inicial mostra 55 documentos, distribuídos entre três páginas, com 11.341 tokens brutos. A média foi de 206,20 tokens por documento, com mínimo de 45 e máximo de 613 tokens. O vocabulário bruto possui 3.285 termos distintos. Esses números indicam que há quantidade suficiente de texto para iniciar os testes de recuperação, embora a distribuição entre as fontes deva ser observada. A distribuição da quantidade de tokens por documento é apresentada na Figura 1.

Figura 1 – Distribuição de tokens por documento



Fonte: Produção Própria (2026)

A distribuição por página mostra o principal ponto de atenção. Santos possui 40 documentos, correspondendo a 72,73% do corpus; São Vicente possui 13 e Fortaleza de Itaipu possui apenas 2. Portanto, o corpus não representa as três fontes de maneira equilibrada. Isso não invalida a coleta, pois Santos também aparece diretamente nas perguntas e possui grande quantidade de informações, mas indica que novas fontes ou páginas poderão ser acrescentadas em etapas posteriores para reduzir a concentração.

Outro diagnóstico importante foi a frequência dos termos. No corpus bruto, os dez termos mais frequentes foram: **de**, **a**, **e**, **o**, **do**, **da**, **em**, **santos**, **que** e **cidade**.

Tabela 1 – Diagnóstico do corpus obtido no notebook

Verificação	Resultado
Documentos	55
Páginas de origem	3
Tokens brutos	11.341
Média de tokens por documento	206,20
Menor documento	45 tokens
Maior documento	613 tokens
Vocabulário bruto	3.285 termos
Página dominante	Santos: 40 documentos (72,73%)
Documentos suspeitos	11 longos; 0 curtos
Acentos, pontuação e números	Presentes

Fonte: Produção Própria (2026)

Tabela 2 – Distribuição dos documentos por página

Página	Documentos	Média de tokens
Fortaleza de Itaipu	2	249
Santos	40	219
São Vicente (São Paulo)	13	160

Fonte: Produção Própria (2026).

A predominância de palavras funcionais mostra a necessidade de uma etapa de limpeza antes da construção do índice de busca. No notebook, essa etapa foi realizada com conversão para minúsculas, remoção de acentos, números e pontuação, remoção de *stopwords*, exclusão de tokens com menos de três caracteres e aplicação de *stemming* em português.

Após a limpeza, o notebook construiu uma representação TF-IDF e uma matriz de documentos e termos. Também foi criado um índice invertido com 2.258 termos indexados. Os termos com maior quantidade de documentos associados foram os radicais **sant**, **cidad**, **sao**, **brasileir** e **paul**, associados respectivamente a 45, 42, 39, 25 e 25 documentos. Isso demonstra que o corpus já pode ser utilizado nas operações básicas do motor.

Foram ainda testadas buscas booleanas. Na consulta AND com “café museu”, foram recuperados os documentos 1, 19 e 32; na consulta OR com os mesmos termos, foram recuperados oito documentos. Também foi testada a busca pelo termo “porto”, que retornou 17 documentos. Esses testes confirmam que o índice invertido permite localizar documentos de acordo com a presença dos termos consultados.

Por fim, o notebook testou o ranking por similaridade de cosseno para as três perguntas de referência. Para a primeira pergunta, o documento mais bem ranqueado foi o **doc_43**, de São Vicente, com similaridade 0,1958. Para a segunda, o primeiro resultado foi novamente o **doc_43**, com 0,0839, enquanto o documento da Fortaleza de Itaipu apareceu em terceiro, com 0,0588. Para a terceira pergunta, relacionada ao comércio do café no porto de Santos,

o doc_1, de Santos, apareceu em primeiro lugar, com similaridade 0,1539; o doc_6, que trata da economia do café e da ligação ferroviária com Santos, apareceu em quarto, com 0,0888.